

Modelado de tópicos en el discurso parlamentario argentino

Cámara de Diputados · 2008–2025

Procesamiento de Lenguaje Natural

Geronimo Fretes · Federico Saroka · Ramón Eppens · Felipe Merlo

Pregunta de investigación

¿Qué temas aparecen en el discurso parlamentario y cómo cambia su prevalencia entre 2008 y 2025?

Objetivo descriptivo: mapear temas y medir su evolución temporal.

Unidad de lectura final: intervenciones parlamentarias reconstruidas desde documentos oficiales.

Corpus final

La unidad de análisis combina intervenciones fuente y chunks no solapados.

392

PDFs oficiales identificados

391

con sesiones analizables

243

sesiones de debate legislativo

75.123

documentos primarios

34.060

intervenciones fuente

15,9M

palabras del corpus primario

Sesión → intervención fuente → documento no solapado

Método

Primero se aisló discurso hablado; después se modelaron temas.


PDFs oficiales → extracción layout-aware → discurso hablado → chunks no solapados → TF-IDF con P1 → NMF → prevalencia temporal

P1 elimina solo cinco tratamientos parlamentarios: señor, señora, señores, presidente y presidenta.

La prevalencia reportada es el peso temático promedio con igual peso por intervención fuente.

Selección del modelo

La especificación principal es NMF con P1 y K=24.



Fuente: grid_metrics.csv, especificación P1. K=24 también maximiza diversidad y exclusividad.

P1 mejora coherencia, diversidad y exclusividad

Métrica	P0	P1	Lectura
Coherencia media NPMI	0.289	0.323	Mayor es mejor
Diversidad top-10	0.942	0.958	Mayor es mejor
Exclusividad media	0.763	0.789	Mayor es mejor
Redundancia media	0.056	0.064	Menor es mejor

P1 elimina solo cinco tratamientos parlamentarios. La pequeña suba de redundancia no compensa las mejoras en las tres métricas principales.

Fuente: grid_metrics.csv de P0 y P1, ambos con K=24. Las matrices fueron ajustadas por separado.

K=24 maximiza coherencia, diversidad y exclusividad dentro de la grilla. P1 mejora la representación sin eliminar vocabulario sustantivo.

Estructura temática

Los 24 componentes combinan agendas sustantivas y lenguaje institucional

Temas sustantivos (11)

- T01 Derecho penal y códigos procesales
- T04 Justicia y Poder Judicial
- T05 Provincias y federalismo
- T08 Desarrollo productivo y economía
- T09 Derechos, género y salud reproductiva
- T10 Trabajo y condiciones laborales
- T16 Poder Ejecutivo, DNU y Constitución
- T17 Presupuesto, gasto e inflación
- T18 Jubilaciones y sistema previsional
- T19 Deuda, FMI y política financiera
- T20 Impuestos y política fiscal

Procedimiento parlamentario (9)

- T02 Redacción artículo por artículo
- T03 Comisiones y actividad parlamentaria
- T07 Proyectos e iniciativas legislativas
- T13 Posiciones de bloque y explicación del voto
- T14 Mociones, reglamento y orden del día
- T15 Modificaciones a proyectos
- T21 Dinámica de Cámara y sesiones
- T22 Inserciones en el Diario de Sesiones
- T23 Cuestiones de privilegio

Retórica y posicionamiento (3)

- T00 Argumentación general y confrontación
- T11 Identidad política y memoria partidaria
- T12 Posicionamiento oficialismo-oposición

Componente residual (1)


- T06 Aplausos y reacciones del recinto

Lectura: el modelo no produce 24 políticas públicas puras. También recupera procedimiento parlamentario, posicionamiento político y un componente residual de reacciones del recinto.

Fuente: términos principales y cinco documentos representativos por tema; etiquetas asignadas manualmente.


Picos temáticos claros

La justicia alcanza una concentración excepcional en 2013



Fuente: prevalencia anual NMF P1 K=24. Estimador principal: igual peso por intervención fuente.

Derechos, género y salud reproductiva alcanzan su máximo en 2018




Fuente: prevalencia anual NMF P1 K=24. Estimador principal: igual peso por intervención fuente.

Ambos máximos se mantienen bajo ponderación por documento, intervención y sesión.

Discurso fiscal

El discurso fiscal se concentra especialmente entre 2021 y 2023




Fuente: prevalencia anual NMF P1 K=24. Estimador principal: igual peso por intervención fuente.

Jubilaciones y sistema previsional

El aumento sostenido aparece mejor en períodos que en un único año pico.

El discurso previsional gana presencia en los períodos recientes



Fuente: prevalencia por períodos NMF P1 K=24. Estimador principal: igual peso por intervención fuente.

Robustez y comparación metodológica


Las conclusiones principales sobreviven a cambios de ponderación; BERTopic queda como benchmark exploratorio.

Las conclusiones principales se mantienen con tres ponderaciones

Hallazgo	Documento	Intervención	Sesión	Misma lectura
Justicia (2013)	8.89%	6.66%	6.03%	Sí
Derechos y género (2018)	11.87%	9.53%	7.20%	Sí
Presupuesto (2021)	7.45%	6.56%	6.07%	Sí
Impuestos (2021)	5.98%	5.17%	6.18%	Sí

Las magnitudes cambian porque cambia la unidad que recibe igual peso. Lo importante es que el año de máxima concentración y la interpretación sustantiva permanecen.

Fuente: prevalencia anual NMF P1 K=24 bajo ponderación por documento, intervención fuente y sesión.



La comparación con BERTopic se basa en cobertura, outliers y rol analítico; no en métricas léxicas incompatibles.

Limitaciones

Las conclusiones describen prevalencia temática, no causalidad ni posiciones ideológicas.

- Las etiquetas son interpretaciones humanas de componentes latentes.
- Los pesos temáticos son mezclas blandas, no clasificaciones binarias.
- Quedan residuos menores de formato, transcripción y palabras partidas.
- Los denominadores anuales varían por disponibilidad y tipo de sesión.
- El análisis no mide causalidad, ideología ni distancia entre bloques.

Conclusiones

El resultado central es una medición temporal defendible sobre discurso hablado.

- Se construyó un corpus válido a partir de PDFs parlamentarios heterogéneos.
- NMF separó agendas sustantivas de procedimiento parlamentario y retórica.
- La prevalencia temporal muestra picos puntuales y cambios persistentes.

Justicia 2013 · Derechos 2018/2020 · Fiscal 2021–2023 · Jubilaciones recientes

Apéndice

Material para preguntas

Apéndice · lista de componentes

Sustantivos: T01 penal; T04 justicia; T05 provincias; T08 desarrollo; T09 derechos/género; T10 trabajo; T16 DNU; T17 presupuesto; T18 jubilaciones; T19 deuda/FMI; T20 impuestos.

Procedimiento: T02 redacción; T03 comisiones; T07 proyectos; T13 posiciones de bloque; T14 mociones; T15 modificaciones; T21 dinámica de sesión; T22 inserciones; T23 privilegio.

Retórica y posicionamiento: T00 argumentación; T11 memoria partidaria; T12 oficialismo-oposición. Residual: T06 aplausos y reacciones.

Los componentes T12 y T15 son interpretables, pero contienen palabras partidas recurrentes.

Apéndice · qué significa prevalencia

Cada documento recibe una mezcla normalizada de 24 pesos temáticos. Para la serie principal, los chunks se promedian dentro de cada intervención fuente y luego cada intervención recibe el mismo peso.

Apéndice · alcance final

- LDA no se incorporó: una corrida apurada no habría sido una comparación justa.
- El análisis por familia política quedó fuera: requería identificación longitudinal de pertenencias.
- La comparación por tipo de sesión se dejó fuera para priorizar profundidad temporal.
- BERTopic se usó como benchmark semántico, no como reemplazo del modelo principal.

Apéndice · BERTopic

Benchmark full-context con BGE-M3 sobre los mismos 75.121 documentos modelados.

- 124 clusters nativos; 23 temas después de reducción.
- 61,2% de cobertura documental y 38,8% de outliers.
- La mejora frente al benchmark MiniLM no se atribuye solo a truncamiento: cambió también el modelo de embeddings.
- Las métricas léxicas no se comparan directamente con NMF porque usan definiciones distintas.